

Do Score ao Erro

Softmax, Perda e Gradientes — um guia intuitivo

Prof. Thiago M. Paixão

Ifes – Campus Serra

Pense num sistema de ranking qualquer — um placar de partida, um retorno de API que atribui uma pontuação a cada opção. É basicamente isso que uma rede neural de classificação faz na última camada: para cada classe possível, ela calcula um score (chamado de *logit*). Só que scores brutos não são probabilidades — podem ser negativos, não somam 1, não são comparáveis entre si de forma direta. Esta nota constrói, passo a passo, a tubulação que transforma esses scores em probabilidades e, a partir delas, em um sinal de erro que a rede usa para aprender.

Vamos do caso mais simples (um único exemplo) até a forma que você de fato escreve em código (mini-batches vetorizados) — e, no caminho, vamos abrir o capô e calcular os gradientes manualmente, sem atalhos, para que a mágica do `loss.backward()` pare de ser mágica.

1 Um único exemplo

Seja $x \in \mathbb{R}^d$ um vetor de entrada (por exemplo, os pixels de uma imagem já achatados em um vetor) e C o número de classes. Cada classe k tem seu próprio detector de score: um vetor de pesos $w_k \in \mathbb{R}^d$ e um viés escalar b_k . Salvo indicação em contrário, todo vetor nesta nota é um **vetor coluna** — isso inclui x e cada w_k .

$$W = \begin{bmatrix} w_1^\top \\ \vdots \\ w_C^\top \end{bmatrix} \in \mathbb{R}^{C \times d}, \quad b = \begin{bmatrix} b_1 \\ \vdots \\ b_C \end{bmatrix} \in \mathbb{R}^C$$

NOTA DE REVISÃO

Como w_k é vetor coluna ($d \times 1$), empilhar os w_k como *linhas* de W exige transpô-los: a linha k de W é $w_k^\top$ ($1 \times d$), não w_k . É essa transposição que faz $W \in \mathbb{R}^{C \times d}$ fechar dimensionalmente e que torna $z_k = w_k^\top x + b_k$ (Passo 1 abaixo) consistente com $z = Wx + b$.

Passo 1 — Scores (logits)

$$z_k = w_k^\top x + b_k, \quad k = 1, \dots, C$$

Cada z_k mede o quanto a entrada x se parece com a classe k , segundo os pesos atuais. É um número real qualquer — pode ser -8.3 , pode ser 52.1 . Ainda não é probabilidade.

INTUIÇÃO

Pense em w_k como um molde aprendido para a classe k . O produto $w_k^\top x$ é literalmente uma medida de similaridade (produto interno) entre a entrada e esse molde: quanto mais x se alinha com w_k , maior o score z_k .

Passo 2 — Softmax: de scores a probabilidades

$$p_k = \text{softmax}(z)_k = \frac{e^{z_k}}{\sum_{j=1}^C e^{z_j}}$$

O softmax faz três coisas ao mesmo tempo: (i) exponencia cada score, tornando tudo positivo; (ii) normaliza pela soma, garantindo $\sum_k p_k = 1$; (iii) exagera as diferenças relativas — um score um pouco maior que os outros vira uma probabilidade proporcionalmente muito maior, graças à exponencial.

INTUIÇÃO

É como transformar os pontos de um campeonato em probabilidade de título. Não basta ter mais pontos que o adversário: o quanto a mais importa, e o softmax captura exatamente essa não linearidade.

Passo 3 — A perda: penalizando a probabilidade errada

Se y é a classe correta do exemplo, a perda de entropia cruzada é:

$$L = -\log(p_y)$$

INTUIÇÃO

$-\log(\cdot)$ é uma função que vale 0 quando o argumento é 1, e explode para $+\infty$ quando o argumento tende a 0. Ou seja: se o modelo acerta com $p_y \approx 1$, a perda é quase nula (sem castigo). Se o modelo erra feio, com $p_y \approx 0$ (achava que a classe correta era quase impossível), a perda dispara. É um professor rigoroso: só reclama quando você erra, e reclama muito mais quanto mais confiante você estava no erro.

$$x \longrightarrow z = Wx + b \longrightarrow p = \text{softmax}(z) \longrightarrow L = -\log p_y$$

Note que a perda depende de todos os z_j (via o denominador do softmax), não apenas de z_y — isso vai importar na hora de derivar.

2 Do exemplo para o dataset inteiro

Com N exemplos $\{(x^{(i)}, y^{(i)})\}_{i=1}^N$, cada um passa pela mesma tubulação (mesmos W , b , compartilhados), gerando seu próprio $z^{(i)}$, $p^{(i)}$ e perda individual $-\log p_{y^{(i)}}^{(i)}$.

A perda do dataset é simplesmente a média das perdas individuais:

$$L(W, b) = \frac{1}{N} \sum_{i=1}^N -\log p_{y^{(i)}}^{(i)}$$

INTUIÇÃO

W e b são os únicos botões que o treinamento pode girar — e eles são compartilhados por todos os N exemplos. Treinar é encontrar os valores de W, b que, em média, deixam o time (todos os exemplos) satisfeito, não apenas um exemplo específico.

3 Do dataset para o mini-batch

Calcular L sobre os N exemplos a cada passo de treino é caro (imagine $N = 1,2$ milhão de imagens). Na prática, sorteia-se um subconjunto pequeno $\mathcal{B} \subset \{1, \dots, N\}$, de tamanho $B = |\mathcal{B}|$ (tipicamente

32, 64, 128...), a cada iteração:

$$L_{\mathcal{B}}(W, b) = \frac{1}{B} \sum_{i \in \mathcal{B}} -\log p_{y^{(i)}}^{(i)}$$

INTUIÇÃO

$L_{\mathcal{B}}$ é uma amostra aleatória de L — como perguntar a B pessoas escolhidas ao acaso, em vez da população inteira, para estimar uma opinião média. Não é exato, mas é um estimador não enviesado ($\mathbb{E}[L_{\mathcal{B}}] = L$) e muitíssimo mais barato de calcular. É essa troca — precisão por velocidade — que viabiliza o treinamento de redes grandes (SGD, Adam, etc.).

Parte II — Abrindo o capô: os gradientes

Agora a pergunta que interessa para o treino: em que direção devo mexer cada peso para diminuir a perda? Essa direção é o gradiente. Vamos calculá-lo primeiro na mão, coordenada a coordenada — e só depois compactar tudo em notação matricial.

4 Gradiente — versão não vetorizada

Queremos $\frac{\partial L}{\partial w_k}$ e $\frac{\partial L}{\partial b_k}$, para cada classe $k = 1, \dots, C$, ainda para um único exemplo.

Passo 1 — gradiente em relação ao score z_k

Aplicando a regra da cadeia através do softmax e do $-\log$, chega-se a um resultado surpreendentemente limpo:

$$\frac{\partial L}{\partial z_k} = p_k - \mathbf{1}[k = y]$$

onde $\mathbf{1}[k = y]$ vale 1 se k é a classe correta, e 0 caso contrário.

PARA OS CURIOSOS — de onde vem essa fórmula

O truque é reescrever L de um jeito que “abra” o softmax em vez de escondê-lo dentro de uma fração. Denotando $S = \sum_{j=1}^C e^{z_j}$ (a soma no denominador do softmax, de modo que $p_j = e^{z_j}/S$):

$$L = -\log(p_y) = -\log\left(\frac{e^{z_y}}{S}\right) = -\log(e^{z_y}) + \log(S) = -z_y + \log(S)$$

(usamos a propriedade $\log(a/b) = \log a - \log b$, e $\log(e^{z_y}) = z_y$). Agora L é uma soma de dois termos bem mais simples de derivar: um termo linear ($-z_y$) e um termo que só depende de S .

Derivando o primeiro termo, $-z_y$, em relação a z_k :

z_y é apenas uma das coordenadas do vetor z — a da classe correta. Derivar z_y em relação a z_k só dá algo diferente de zero quando k é exatamente essa coordenada:

$$\frac{\partial(-z_y)}{\partial z_k} = -\mathbf{1}[k = y]$$

Derivando o segundo termo, $\log(S)$, em relação a z_k :

Aqui usamos a regra da cadeia ($\frac{d}{du} \log(u) = \frac{1}{u} \cdot \frac{du}{dz_k}$) com $u = S$:

$$\frac{\partial \log(S)}{\partial z_k} = \frac{1}{S} \cdot \frac{\partial S}{\partial z_k}$$

Como $S = \sum_{j=1}^C e^{z_j}$, e apenas o termo $j = k$ dessa soma depende de z_k :

$$\frac{\partial S}{\partial z_k} = \frac{\partial}{\partial z_k} \sum_{j=1}^C e^{z_j} = e^{z_k}$$

Substituindo de volta:

$$\frac{\partial \log(S)}{\partial z_k} = \frac{e^{z_k}}{S} = p_k$$

(a última igualdade é só a própria definição de softmax — $p_k = e^{z_k}/S$.)

Somando os dois termos:

$$\frac{\partial L}{\partial z_k} = \underbrace{-\mathbf{1}[k = y]}_{\text{do termo } -z_y} + \underbrace{p_k}_{\text{do termo } \log(S)} = p_k - \mathbf{1}[k = y]$$

Repare que não precisamos separar na mão os casos $k = y$ e $k \neq y$ — o indicador $\mathbf{1}[k = y]$ já nasce naturalmente da derivada de z_y e carrega essa distinção sozinho. Mas, para conferir, vale substituir os dois casos:

- Se $k = y$: $\partial L / \partial z_k = p_y - 1$ (negativo, pois $p_y \leq 1$).
- Se $k \neq y$: $\partial L / \partial z_k = p_k - 0 = p_k$ (positivo, pois $p_k \geq 0$).

exatamente os dois comportamentos discutidos na caixa de intuição acima.

INTUIÇÃO

Esse termo é literalmente o erro de cada score: a diferença entre o que o modelo previu (p_k) e o que deveria ter previsto (1 para a classe certa, 0 para as demais). Se o modelo acerta perfeitamente ($p_y = 1$, $p_{k \neq y} = 0$), esse erro é zero em todas as coordenadas — e o gradiente desaparece, sinalizando nada a corrigir aqui.

Passo 2 — propagando até w_k e b_k

Como $z_k = w_k^\top x + b_k$, temos $\frac{\partial z_k}{\partial w_k} = x$ e $\frac{\partial z_k}{\partial b_k} = 1$. Pela regra da cadeia:

$$\frac{\partial L}{\partial w_k} = (p_k - \mathbf{1}[k = y]) x, \quad \frac{\partial L}{\partial b_k} = p_k - \mathbf{1}[k = y]$$

PARA OS CURIOSOS — de onde vem essa fórmula

Formalmente, L depende de w_k através do vetor z inteiro (não só de z_k), então a regra da cadeia multivariada exige, a rigor, um somatório sobre todas as coordenadas de z :

$$\frac{\partial L}{\partial w_k} = \sum_{j=1}^C \frac{\partial L}{\partial z_j} \cdot \frac{\partial z_j}{\partial w_k}$$

Mas cada classe tem seu próprio vetor de pesos, sem compartilhamento: $z_j = w_j^\top x + b_j$ depende apenas de w_j , nunca de w_k com $k \neq j$. Logo

$$\frac{\partial z_j}{\partial w_k} = \begin{cases} x, & j = k \\ 0, & j \neq k \end{cases}$$

e o somatório colapsa num único termo sobrevivente ($j = k$):

$$\frac{\partial L}{\partial w_k} = \frac{\partial L}{\partial z_k} \cdot x = (p_k - \mathbf{1}[k = y]) x$$

É por isso que a passagem acima pôde ir direto de $\partial z_k / \partial w_k = x$ ao resultado final, sem mencionar os demais $C - 1$ termos: eles são todos nulos.

INTUIÇÃO

Se k é a classe correta ($k = y$): o gradiente é $(p_y - 1)x$, e como $p_y \leq 1$ esse fator é ≤ 0 . O passo de descida do gradiente (que subtrai o gradiente) vai então aumentar $w_y^\top x$ — empurrando p_y para mais perto de 1. Faz sentido: queremos reforçar a classe certa.

Se k é uma classe errada ($k \neq y$): o gradiente é $p_k \cdot x$, positivo. O passo de descida vai diminuir $w_k^\top x$ — suprimindo a confiança nas classes erradas. O modelo está literalmente roubando probabilidade das classes erradas para dar à classe certa.

5 Forma vetorizada

Empilhar C equações escalares repetidas é sinal de que dá para escrever em forma vetorial. Defina o vetor de erro $\delta \in \mathbb{R}^C$:

$$\delta = p - y_{\text{one-hot}}, \quad \text{onde } y_{\text{one-hot}} = (\mathbf{1}[1 = y], \dots, \mathbf{1}[C = y])^\top$$

Ou seja, δ é simplesmente o vetor de probabilidades previstas menos um vetor com 1 na posição da classe correta e 0 nas demais. Os gradientes da Seção 4, todos de uma vez, ficam:

$$\frac{\partial L}{\partial W} = \delta x^\top \in \mathbb{R}^{C \times d}, \quad \frac{\partial L}{\partial b} = \delta \in \mathbb{R}^C$$

CHECAGEM DE SANIDADE

$\delta \in \mathbb{R}^{C \times 1}$ e $x^\top \in \mathbb{R}^{1 \times d}$: o produto $\delta x^\top$ é um produto externo (*outer product*), resultando numa matriz $C \times d$ — não um escalar (isso seria $\delta^\top x$, que nem faz sentido dimensional aqui) e não um vetor. A entrada (k, i) dessa matriz é $\delta_k \cdot x_i$, que é exatamente $\partial L / \partial W_{k,i}$: o quanto a perda muda se eu mexer no peso que conecta a feature i à classe k .

Sempre que calcular um gradiente, cheque se a forma bate com a forma do parâmetro original: $\partial L / \partial W$ tem que ter a mesma forma de W ($C \times d$), assim como $\partial L / \partial b$ tem que ter a mesma forma de b (C). Se as dimensões não baterem, há um erro na conta.

6 De volta ao dataset e ao mini-batch

Como L (ou L_B) é uma média de perdas individuais, seu gradiente é a média dos gradientes individuais — a derivada de uma soma é a soma das derivadas:

$$\frac{\partial L_B}{\partial W} = \frac{1}{B} \sum_{i \in \mathcal{B}} \delta^{(i)} (x^{(i)})^\top, \quad \frac{\partial L_B}{\partial b} = \frac{1}{B} \sum_{i \in \mathcal{B}} \delta^{(i)}$$

A forma que aparece no código

Empilhando os exemplos do mini-batch em matrizes — $X_B \in \mathbb{R}^{B \times d}$ (uma linha $(x^{(i)})^\top$ por exemplo) e $\Delta \in \mathbb{R}^{B \times C}$ (uma linha $(\delta^{(i)})^\top$ por exemplo) — a soma acima vira um único produto de matrizes:

$$\frac{\partial L_B}{\partial W} = \frac{1}{B} \Delta^\top X_B \in \mathbb{R}^{C \times d}, \quad \frac{\partial L_B}{\partial b} = \frac{1}{B} \sum_{i \in \mathcal{B}} \Delta_{i,:} \in \mathbb{R}^C$$

NOTA DE REVISÃO

Assim como em W (Seção 1), X_B empilha vetores coluna $(x^{(i)})$ como *linhas*, o que exige transpô-los: a linha i de X_B é $(x^{(i)})^\top$, não $x^{(i)}$. A definição de Δ já trazia essa transposição explícita; agora as duas ficam no mesmo padrão.

INTUIÇÃO

É essa vetorização — trocar um laço `for` sobre B exemplos por um único produto de matrizes — que faz frameworks como PyTorch e TensorFlow rodarem rápido em GPU. Mas por trás de cada chamada a `loss.backward()` está exatamente a conta que fizemos à mão nas Seções 4 e 5: nada mágico, só álgebra linear organizada.

Para praticar

1. Refaça, com suas próprias palavras (sem olhar a caixa *Para os curiosos*), a derivação de $\partial L / \partial z_k = p_k - \mathbf{1}[k = y]$ a partir de $L = -z_y + \log(S)$. É um ótimo treino de regra da cadeia.
2. Para $C = 3$ classes e um exemplo com $z = (2.0, 1.0, 0.1)$ e classe correta $y = 1$ (primeira classe), calcule p , L e δ na mão.
3. Implemente as fórmulas vetorizadas da Seção 6 em NumPy, para um mini-batch de $B = 4$ exemplos e $C = 3$ classes, e confira as formas (`.shape`) de cada gradiente contra a checagem de sanidade da Seção 5.